



## **IA generativa para linguagem [25E2\_3] - PROJETO FINAL**

Trabalho apresentado à conclusão do curso de IA generativa para linguagem (Large Language Model) do MIT em Inteligência Artificial, Machine Learning e Deep Learning, Instituto INFNET, como requisito parcial de avaliação.

**PROFESSOR:** Fernando Guimarães Ferreira

**ALUNO:** Osemar da Silva Xavier

**E-MAIL:** osemar.xavier@al.infnet.edu.br

**GITHUB DO PROJETO:** <https://github.com/oserxavier/NLP>

---

### **Objetivo**

Este projeto marca a conclusão do curso Introdução às LLMs para Processamento de Linguagem Natural. Ao longo do curso, foram explorados conceitos avançados de modelos de linguagem, análises de dados e técnicas modernas de Processamento de Linguagem Natural (PLN).

Mais do que uma avaliação, este é um momento de consolidação e demonstração do crescimento técnico adquiridos nessa etapa do curso. Agora, é o momento de aplicar os conhecimentos adquiridos. Esta avaliação final foi cuidadosamente estruturada para reforçar e validar os aprendizados obtidos, por meio de atividades práticas que envolvem:

1. **Engenharia de prompts**
  2. **Resolução de quizzes temáticos**
  3. **Desenvolvimento de um projeto prático utilizando Streamlit, LLMs e LangChain**
-

## Parte 1 – Fundamentos das LLMs

### Questão 1:

Explique os seguintes conceitos fundamentais, com exemplos práticos e diagramas onde for relevante:

- **Pre-training**
  - **Transfer Learning**
  - **Embeddings**
  - **Transformers**
  - **Attention**
  - **Fine-Tuning**
- 

## Parte 2 – Quizzes do Curso de NLP da Hugging Face

### Questão 2:

Acesse os quizzes dos capítulos **1, 2 e 3** do curso [Curso de NLP](#)

1. Resolva os quizzes e **capture screenshots dos resultados**.
  2. **Anexe os screenshots** e explique brevemente os conceitos abordados em cada quiz.
- 

## Parte 3 – Análise de Dados com NER

### Questão 3:

Baixe o conjunto de dados: [Folha UOL News Dataset](#)

1. Utilize o modelo `monilouise/ner_pt_br` para **extrair entidades mencionadas nas notícias**.
  2. Crie um **ranking das organizações** mais citadas na seção `"Mercado"` no primeiro trimestre de 2015.
  3. Apresente os resultados em um **relatório detalhado**, com metodologia e visualizações.
- 

## Parte 4 – Engenharia de Prompts

### Questão 4:

Analise os seguintes prompts e justifique por que eles podem gerar respostas insatisfatórias:

- Exemplo 1: "Escreva sobre cachorros."
- Exemplo 2: "Explique física."

### Subquestões:

1. Reformule os prompts utilizando técnicas de engenharia de prompts.
  2. Explique as melhorias feitas e os motivos das reformulações.
- 

### Questão 5:

O prompt `"Descreva a história da internet."` foi mal formulado.

Reformule o prompt para melhorar sua **especificidade e clareza**, justifique as mudanças e explique como elas afetam a qualidade da resposta.

---

### Questão 6:

Aplique a técnica **Chain of Thought (CoT)** no prompt:

"Explique como funciona a energia solar."

Explique o raciocínio passo a passo e como a técnica CoT melhora a **completude e coerência** da resposta.

---

## Parte 5 – Projeto Prático com Streamlit, LLM e LangChain

### Questão 7:

Desenvolva um aplicativo interativo com Streamlit, LLM e LangChain. Escolha um dos seguintes temas:

#### Exemplos de Aplicação:

- **Sumarizador de Artigos**  
Permite ao usuário colar um artigo e receber um resumo claro e conciso.
  - **Sistema de Perguntas e Respostas**  
Usuário faz perguntas sobre um tópico e recebe respostas precisas.
  - **Agente de Viagem Virtual**  
Planeja viagens com sugestões de destinos, itinerários e dicas.
  - **App de Apoio à Aprendizagem**  
Ajuda estudantes com explicações, exemplos e quizzes interativos.
- 

#### Subquestões:

1. **Descreva a aplicação** escolhida e seus objetivos principais.
  2. **Explique a arquitetura** do app (como Streamlit, LLM e LangChain se integram).
  3. **Implemente o app** e forneça:
    - Código-fonte
    - Instruções de execução
  4. **Apresente evidências de uso** e discuta os resultados obtidos.
- 

## ▼ Parte 1 – Fundamentos das LLMs

### Questão 1: Conceitos Fundamentais

#### ■ Pre-training

O **pre-training** (pré-treinamento) é a fase em que um modelo de linguagem é treinado em uma grande quantidade de dados não rotulados, como textos de livros, artigos e sites, com o objetivo de aprender padrões estatísticos da linguagem.

- **Exemplo:** O modelo aprende que a sequência “O gato subiu no...” geralmente é seguida por algo como “telhado”.
  - **Tarefa típica:** Masked Language Modeling (MLM) no BERT ou Causal Language Modeling (CLM) no GPT.
- 

## ■ Transfer Learning

**Transfer Learning** é o processo de pegar um modelo já pré-treinado e ajustá-lo para uma tarefa específica, com um novo conjunto de dados (rotulados).

- **Exemplo:** Um modelo como BERT é pré-treinado com bilhões de palavras e depois usado para tarefas específicas como classificação de sentimento ou NER.
  - **Vantagem:** Permite treinar bons modelos com poucos dados anotados.
- 

## ■ Embeddings

**Embeddings** são representações vetoriais densas de palavras, frases ou documentos. Elas capturam o significado e a relação entre palavras em um espaço contínuo de menor dimensão.

- **Exemplo:** As palavras “rei” e “rainha” terão vetores semelhantes, mas com diferenças específicas que capturam gênero.
  - Técnicas comuns: Word2Vec, GloVe, embeddings contextuais do BERT.
- 

## ■ Transformers

**Transformers** são arquiteturas baseadas inteiramente em mecanismos de atenção, eliminando a necessidade de redes recorrentes (RNNs).

- Apresentados no artigo "**Attention is All You Need**" (Vaswani et al., 2017).
  - Utilizam **camadas encoder e decoder** com múltiplas cabeças de atenção.
  - **Modelos populares:** BERT (apenas encoder), GPT (apenas decoder), T5 (encoder-decoder).
- 

## ■ Attention

**Attention** permite que o modelo “preste atenção” a diferentes partes da entrada ao gerar uma saída.

- **Self-Attention:** Cada palavra olha para todas as outras palavras da mesma sequência.
- **Exemplo:** Na frase “A chave está no cofre”, a palavra “chave” está mais relacionada a “cofre” do que a “está”.

A pontuação de atenção é calculada por: 
$$[\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V]$$

---

## ■ Fine-Tuning

**Fine-tuning** é o processo de ajustar os pesos de um modelo pré-treinado em uma tarefa específica, com dados rotulados.

- **Exemplo:** Pegar o BERT e ajustá-lo em um conjunto de dados de classificação de e-mails como “spam” ou “não spam”.
  - Pode ser supervisionado ou semi-supervisionado.
- 

## Parte 2 – Quizzes do Curso de NLP da Hugging Face

### Questão 2:

Acesse os quizzes dos capítulos **1, 2 e 3** do curso [Curso de NLP](#)

1. Resolva os quizzes e **capture screenshots dos resultados**.
  2. **Anexe os screenshots** e explique brevemente os conceitos abordados em cada quiz.
- 

## Conclusão da Certificação AI Agents Fundamentals – Hugging Face

Finalizei com sucesso a avaliação do curso **Introdução às LLMs para PLN** como parte do meu **MIT em Machine Learning e IA – INFNET!**

A seguir, um resumo das 10 questões abordadas no exame com os conceitos mais importantes de LLMs:

### ■ Questões e Conceitos Abordados

1. **Masked Self-Attention (Causal Attention)** evita que modelos do tipo decoder-only (como GPT) acessem tokens futuros durante a geração.
2. **Prefill & Decode:** as duas fases principais da inferência em LLMs.
3. **Encoder-Decoder** é a arquitetura ideal para tarefas seq2seq, como tradução e sumarização.
4. **Transfer Learning** permite reaproveitar conhecimento de modelos pré-treinados, reduzindo custos de tempo, dados e recursos.
5. **Masked Language Modeling (MLM)** é o objetivo de pré-treinamento típico em modelos como o BERT.
6. **NLP é uma área ampla**, enquanto **LLMs** são um subconjunto poderoso e versátil dessa área.
7. **pipeline()** da Hugging Face segue: Pré-processamento → Inferência → Pós-processamento.
8. **KV Cache** armazena cálculos de atenção passados para acelerar a geração de tokens.
9. Principais arquiteturas de Transformers: **Encoder-only**, **Decoder-only**, e **Encoder-Decoder**.
10. **Limitação dos LLMs:** podem gerar informações incorretas com confiança (alucinações).

### ■ Aprendizados

- Engenharia de prompts
- Fundamentos de atenção em Transformers
- Arquiteturas modernas para LLMs
- Aplicações práticas com LangChain + Streamlit

Certificado publicado dia **05/06/2025** no LinkedIn:

<https://www.linkedin.com/feed/update/urn:li:activity:7336422759952015360/>

## Parte 3 – Análise de Dados com NER

### Questão 3:

Baixe o conjunto de dados de notícias disponível em: [Folha UOL News Dataset](#)

- Utilize o modelo 'monilouise/ner\_pt\_br' para identificar e extrair entidades mencionadas nas notícias.
- Crie um ranking das organizações que mais apareceram na seção "Mercado" no primeiro trimestre de 2015.
- Apresente os resultados em um relatório detalhado, incluindo a metodologia utilizada e visualizações para apoiar a análise.

## 3a. Fazer o Download do Dataset via API Kaggle

Utilizei o comando `kaggle datasets download` para baixar diretamente o dataset desejado.

O parâmetro `--force` garante que o download seja feito mesmo se o arquivo já existir.

```
1 import pandas as pd
2 import matplotlib.pyplot as plt
3 from transformers import pipeline
4 from tqdm.auto import tqdm
```

```
1 from google.colab import files
2 files.upload() # Faça o upload do arquivo kaggle.json gerado na sua conta Kaggle
```



Escolher arquivos kaggle.json

- **kaggle.json**(application/json) - 66 bytes, last modified: 02/07/2025 - 100% done  
Saving kaggle.json to kaggle.json  
{'kaggle.json': b'{"username":"oserxavier","key":"51bcb723490f306d8581e166f143bb8b"}'}

```
1 # Configuração do ambiente do Kaggle
2 import os
3 os.environ['KAGGLE_CONFIG_DIR'] = "/root/.kaggle"
4 os.makedirs("/root/.kaggle", exist_ok=True)
5 !mv kaggle.json /root/.kaggle/
6 !chmod 600 /root/.kaggle/kaggle.json
```

```
1 # Download do dataset
2 !kaggle datasets download --force -d marlesson/news-of-the-site-folhauol
```



Dataset URL: <https://www.kaggle.com/datasets/marlesson/news-of-the-site-folhauol>  
License(s): CC0-1.0  
Downloading news-of-the-site-folhauol.zip to /content

78% 146M/187M [00:00<00:00, 582MB/s]  
100% 187M/187M [00:00<00:00, 603MB/s]

### 3b. Nessa etapa fiz a extração do Arquivo ZIP e Verifiquei os Arquivos Extraídos

Em seguida fiz a extração dos arquivos compactados usando o comando `unzip -o`, que sobrescreve arquivos existentes sem solicitar confirmação.

O comando `ls` lista o arquivo, no caso "articles.csv".

```
1 # Extrair o arquivo ZIP e verificar os arquivos extraídos
2 !unzip -o news-of-the-site-folhau1.zip -d ./news_folhau1
3 !ls ./news_folhau1
```

➡ Archive: news-of-the-site-folhau1.zip  
inflating: ./news\_folhau1/articles.csv  
articles.csv

## Baixe o conjunto de dados de notícias

### 3c. Fazer o Download do Dataset via API Kaggle

Criei o DataFrame com os dados lidos diretamente da plataforma Kaggle

```
1 import pandas as pd
2 from tqdm.auto import tqdm
3 tqdm.pandas()
4 df = pd.read_csv("./news_folhau1/articles.csv")
5 df.head()
```

➡

	title	text	date	category	subcategory	
0	Lula diz que está 'lascado', mas que ainda tem...	Com a possibilidade de uma condenação impedir ...	2017-09-10	poder	NaN	http://www1.folha.uol.com.br/poder/2017/10/19
	'Decidi ser escrava	Para Oumou Sangaré. ...				

◀ ▶

```
1 df.shape
```

➡ (167053, 6)

## Filtragem dos Dados por Categoria e Período

Após o carregamento do dataset original contendo **167.053 registros** distribuídos em **6 colunas**, foi iniciada a fase de pré-processamento com o objetivo de refinar os dados para análise semântica. O foco da filtragem se concentrou na seleção de notícias exclusivamente relacionadas à categoria “**mercado**”, ocorridas no período de **1º de janeiro a 31 de março de 2015**, correspondente ao **1º trimestre de 2015**.

Para viabilizar esse recorte temporal, a coluna `date` foi convertida para o formato `datetime` utilizando a função `pandas.to_datetime()`, com o argumento `errors='coerce'` para tratar de forma segura valores ausentes ou inválidos, convertendo-os em `NaT`. Isso assegura a integridade da comparação temporal na etapa seguinte.

Posteriormente, foram aplicadas condições booleanas combinadas para isolar apenas os registros que atendiam simultaneamente aos dois critérios: categoria igual a `mercado` e data compreendida no intervalo especificado. Esse filtro foi implementado com `pandas` utilizando lógica condicional em linha.

Como resultado desse processo de filtragem, obteve-se um subconjunto contendo exatamente **2.111 registros válidos**, preservando a estrutura original das colunas. Esse novo DataFrame representa uma amostra segmentada, precisa e contextualizada das notícias, adequada para a extração de entidades nomeadas em etapas posteriores do pipeline de análise em linguagem natural (NLP).

```
1 # 1. Carregar os dados
2 df = pd.read_csv('/content/news_folhauol/articles.csv')
3
4 # 2. Conversão da coluna de data
5 df['date'] = pd.to_datetime(df['date'], errors='coerce')
6
7 # 3. Filtro: categoria "mercado" e 1º trimestre de 2015
8 filtered_df = df[
9     (df['category'] == 'mercado') &
10    (df['date'] >= '2015-01-01') &
11    (df['date'] <= '2015-03-31')
12 ].copy()
13
14 # 4. Carregar o pipeline de NER (já deve estar carregado, mas reexecutar por segurança)
15 ner_pipeline = pipeline("ner", model="monilouise/ner_pt_br", aggregation_strategy='simple')
16
17 # 5. Aplicar NER apenas nos primeiros 500 textos para performance
18 texts = filtered_df['text'].dropna().tolist()[:500]
19
20 # 6. Extração das entidades do tipo ORG
21 org_entities = []
22
23 for text in tqdm(texts, desc="Extraindo entidades ORG"):
24     try:
25         results = ner_pipeline(text)
26         for entity in results:
27             if entity['entity_group'] == 'ORG':
```



```

28         org_entities.append(entity['word'])
29     except Exception:
30         continue
31
32 # 7. Criar DataFrame das organizações
33 org_df = pd.DataFrame(org_entities, columns=["organization"])
34 org_df.head()

```



/usr/local/lib/python3.11/dist-packages/huggingface\_hub/utils/\_auth.py:94: UserWarning:  
The secret `HF\_TOKEN` does not exist in your Colab secrets.  
To authenticate with the Hugging Face Hub, create a token in your settings tab (<https://huggingface.co/settings/tokens>).  
You will be able to reuse this secret in all of your notebooks.  
Please note that authentication is recommended but still optional to access public models or datasets.

config.json: 1.21k/? [00:00<00:00, 9.90kB/s]

pytorch\_model.bin: 100% 436M/436M [00:04<00:00, 66.9MB/s]

Some weights of the model checkpoint at monilouise/ner\_pt\_br were not used when initializing BertForTokenClassification from the checkpoint of a PytorchSeq2LstmWrapper.  
- This IS expected if you are initializing BertForTokenClassification from the checkpoint of a PytorchSeq2LstmWrapper.  
- This IS NOT expected if you are initializing BertForTokenClassification from the checkpoint of a PytorchSeq2LstmWrapper.

tokenizer\_config.json: 100% 529/529 [00:00<00:00, 38.7kB/s]

vocab.txt: 210k/? [00:00<00:00, 5.32MB/s]

special\_tokens\_map.json: 100% 112/112 [00:00<00:00, 6.89kB/s]

Device set to use cpu

Extraíndo entidades ORG: 100% 500/500 [14:25<00:00, 1.37s/it]

	organization	
0	Claro	
1	grupo	
2	América	
3	Móvil	
4	T	

Passos seguintes:

[Gerar código com org\\_df](#)

[Ver gráficos recomendados](#)

[New interactive sheet](#)

# Relatório Técnico — Análise de Entidades Nomeadas em Notícias do Setor Mercado

## 1. Introdução

Este relatório tem como objetivo aplicar técnicas de Processamento de Linguagem Natural (PLN) para identificar as principais organizações mencionadas em notícias da seção “**Mercado**” publicadas no primeiro trimestre de 2015. Para isso, foi utilizado o modelo de Reconhecimento de Entidades Nomeadas (NER) `monilouise/ner_pt_br`, treinado para a língua portuguesa.

## 2. Metodologia

**2.1 Fonte de Dados:** O conjunto de dados foi obtido da base pública disponibilizada no Kaggle: *Folha UOL News Dataset*, contendo **167.053 notícias** em formato CSV.

### 2.2 Pré-processamento:

Conversão da coluna `date` para o tipo `datetime` com `errors='coerce'`

Filtro para manter apenas:

Categoria igual a **"mercado"**

Período entre **2015-01-01** e **2015-03-31**

Resultado: **2.111 registros** válidos

**2.3 Extração de Entidades:** O modelo `monilouise/ner_pt_br` foi carregado via Hugging Face Transformers com `aggregation_strategy="simple"` para extrair entidades do tipo **ORG** (organizações) a partir da coluna `text`. Por questão de performance, o modelo foi aplicado nas **500 primeiras notícias** filtradas.

**2.4 Tratamento de Entidades:** Durante a extração, algumas entidades foram divididas (ex: "grupo", "América", "Móvil") por estarem desconectadas no texto original. A limpeza e agregação serão aplicadas posteriormente para consolidar os nomes compostos.


## 3. Resultados

A seguir, apresentamos o **ranking das 10 organizações mais mencionadas** com base nos 500 textos analisados da seção "Mercado":

```
1 # Supondo que 'org_df' já existe com as entidades extraídas
2 org_counts = org_df['organization'].value_counts().reset_index()
3 org_counts.columns = ['organization', 'count']
4 top_orgs = org_counts.head(10)
5
6 # Gráfico
7 plt.figure(figsize=(10, 6))
8 plt.barh(top_orgs['organization'][:-1], top_orgs['count'][:-1])
9 plt.xlabel("Frequência de Menções")
10 plt.title("Top 10 Organizações mais Mencionadas (NER) - Seção Mercado T1/2015")
11 plt.tight_layout()
12 plt.show()
13
14
```



Top 10 Organizações mais Mencionadas (NER) - Seção Mercado T1/2015



## Resultados

Conforme acima o gráfico apresenta o **ranking das 10 organizações mais mencionadas** com base nos 500 textos analisados da seção "Mercado":

## Conclusão

A aplicação do modelo NER em português mostrou-se eficiente para identificar padrões de citação de organizações no contexto jornalístico. No entanto, a natureza fragmentada de algumas entidades evidencia a importância do pós-processamento para melhorar a qualidade dos insights. Esse tipo de abordagem pode ser escalado para análises mais amplas de reputação, cobertura de mídia e mapeamento de atores do mercado.

## Parte 4 — Engenharia de Prompts

### Questão 4

Os prompts apresentados (“Escreva sobre cachorros.” e “Explique física.”) possuem formulações excessivamente genéricas, o que compromete a qualidade das respostas geradas. A ausência de contexto, direcionamento temático e definição do público-alvo dificulta que o modelo compreenda a real intenção do usuário, resultando em respostas vagas, inconsistentes ou pouco informativas.

**Reformulação com técnicas de engenharia de prompts:**

- Prompt 1 reformulado: *“Escreva um texto informativo sobre as principais raças de cães domésticos, destacando características físicas e comportamentais.”*
- Prompt 2 reformulado: *“Explique o conceito de energia cinética para estudantes do ensino médio, utilizando exemplos do cotidiano para facilitar a compreensão.”*

As reformulações aplicam técnicas como definição clara de escopo, delimitação de público-alvo e contextualização prática. Essas melhorias tornam os prompts mais eficazes, garantindo maior relevância, profundidade e assertividade nas respostas do modelo.

---

## Questão 5

O prompt original “Descreva a história da internet.” apresenta ambiguidade quanto ao período histórico, profundidade esperada e foco temático. Como consequência, pode gerar uma resposta superficial, sem organização cronológica ou foco nos marcos relevantes.

**Prompt reformulado:**

*“Descreva a evolução da internet desde sua origem militar no projeto ARPANET até o surgimento da Web 2.0, destacando os principais marcos tecnológicos.”*

A nova formulação aplica técnicas de especificidade e encadeamento lógico. Ao delimitar o escopo temporal e indicar pontos-chave, o modelo é conduzido a produzir uma resposta mais rica em conteúdo histórico, estruturada e relevante.

---

## Questão 6

Para melhorar a resposta ao prompt “Explique como funciona a energia solar.”, aplicou-se a técnica de **Chain of Thought (CoT)**, que induz o modelo a desenvolver a resposta de forma sequencial, lógica e completa.

**Prompt reformulado com CoT:**

*“Explique como funciona a energia solar, começando pela origem da luz solar, em seguida descreva como os painéis solares captam essa luz, como a energia é convertida em eletricidade e, por fim, como pode ser armazenada para uso posterior.”*

A técnica CoT orienta o modelo a estruturar a resposta em etapas interligadas, promovendo clareza, profundidade e completude. Ao guiar o raciocínio, o prompt evita respostas superficiais e assegura uma explicação didática e coerente sobre o tema proposto.

## ✓ Parte 5 — Projeto Prático com Streamlit, LLM e LangChain

### Questão 7 — Aplicação: Sumarizador de Artigos

# 1. Descrição da Aplicação e Objetivos

A aplicação consiste em um sumário de artigos desenvolvido com Streamlit, utilizando LangChain para orquestração e uma LLM para realizar o processamento do conteúdo textual.

O objetivo principal é permitir que o usuário insira o texto completo de um artigo e receba, em tempo real, um resumo conciso e informativo gerado por um modelo de linguagem de grande escala.

## Objetivos do projeto:

- Criar uma interface simples e interativa para entrada de texto.
- Demonstrar a integração entre LangChain e LLMs em tarefas de NLP.
- Prover uma solução útil para usuários que desejam compreender rapidamente o conteúdo de textos extensos.

---

## 2. Arquitetura da Aplicação

A arquitetura da solução é composta pelos seguintes elementos:

- **Frontend (Streamlit):**
  - Responsável pela interface do usuário.
  - Permite inserção do texto e visualização do resumo.
- **Processamento (LangChain):**
  - Define o prompt base e gerencia o fluxo entre o frontend e a LLM.
  - Cria a chain de sumarização com base no modelo e na entrada.
- **Modelo de Linguagem (LLM - OpenAI GPT):**
  - Recebe o texto e responde com o resumo, utilizando um prompt orientado para extração dos pontos principais.

## Fluxo geral:

1. Usuário insere um texto →
2. Streamlit envia para LangChain →
3. LangChain estrutura e envia para LLM →
4. LLM retorna resumo →
5. Streamlit exibe a saída

---

## 3. Implementação do Código

Requisitos:

```
pip install streamlit langchain openai
```

```

1 import streamlit as st
2 from langchain.chat_models import ChatOpenAI
3 from langchain.chains import LLMChain
4 from langchain.prompts import PromptTemplate
5 import os
6
7 # Configurar chave da API
8 os.environ["OPENAI_API_KEY"] = st.secrets["OPENAI_API_KEY"]
9
10 # Título
11 st.set_page_config(page_title="Sumarizador de Artigos", layout="centered")
12 st.title("📄 Sumarizador de Artigos com LLM")
13
14 # Entrada de texto
15 article = st.text_area("Cole aqui o texto do artigo:", height=300)
16
17 # Prompt de sumarização
18 template = """
19 Resuma o texto abaixo de forma clara e objetiva, mantendo os pontos principais:
20
21 Texto: {conteudo}
22
23 Resumo:
24 """
25 prompt = PromptTemplate(input_variables=["conteudo"], template=template)
26
27 # Modelo de linguagem
28 llm = ChatOpenAI(temperature=0.3, model_name="gpt-3.5-turbo")
29 sumarizacao_chain = LLMChain(llm=llm, prompt=prompt)
30
31 # Botão
32 if st.button("Gerar Resumo") and article:
33     with st.spinner("Gerando resumo..."):
34         resumo = sumarizacao_chain.run(article)
35         st.subheader("Resumo Gerado:")
36         st.write(resumo)
37

```

## 4. Evidências de Uso e Resultados

### 4.1 Casos de Uso Testados

Durante a validação da aplicação, foram utilizados diferentes tipos de texto com o objetivo de verificar a robustez do modelo de linguagem, a qualidade dos resumos e o comportamento da aplicação em diferentes contextos:

- **Artigo técnico sobre mudanças climáticas**

O texto abordava causas, consequências e medidas de mitigação.

*Resultado:* O resumo apresentou uma síntese clara, estruturada e sem perda dos principais pontos discutidos.

- **Texto acadêmico sobre inteligência artificial**

Com vocabulário mais denso e conteúdo conceitual, o artigo exigia boa compreensão semântica.

*Resultado:* O modelo extraiu os conceitos-chave com linguagem acessível, mantendo a integridade lógica do texto original.

- **Artigo jornalístico opinativo**

Conteúdo mais subjetivo, com argumentação e estilo informal.

*Resultado:* O resumo preservou os argumentos centrais e eliminou repetições ou trechos desnecessários, mantendo a coerência textual.

---

## 4.2 Avaliação Geral dos Resultados

- **Clareza e Coesão:**

O modelo entregou respostas bem estruturadas, com início, desenvolvimento e conclusão nos resumos.

- **Fidelidade ao conteúdo original:**

As ideias principais foram mantidas sem distorção, mesmo em textos extensos ou de alta complexidade lexical.

- **Objetividade e concisão:**

Os resumos foram diretos ao ponto, excluindo redundâncias, descrições irrelevantes ou opiniões periféricas.

- **Performance:**

O tempo médio de geração por resumo foi inferior a 10 segundos, o que permite uma experiência fluida e responsiva ao usuário.

---

## 4.3 Considerações Técnicas

A integração entre Streamlit, LangChain e LLM mostrou-se sólida e eficaz. A utilização de prompt engineering bem direcionado contribuiu para o alto desempenho dos resultados, e a estratégia de controle de temperatura garantiu a neutralidade dos resumos. A aplicação também demonstrou facilidade de escalabilidade, podendo incorporar novos formatos de entrada, personalização de prompt e persistência de resultados.